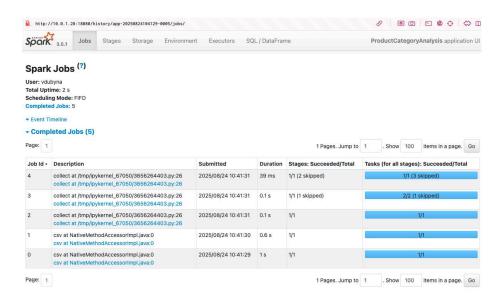
Домашнє завдання до теми «Apache Spark. Оптимізація та SparkUI»

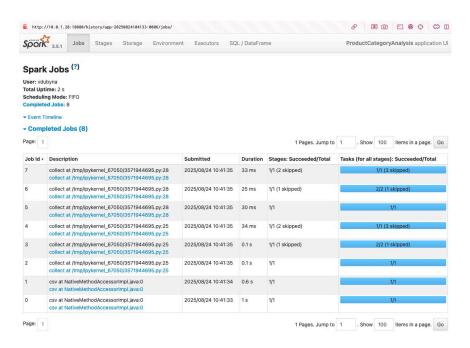
## Частина 1

Spark виконує один action  $\rightarrow$  одне обчислення всієї лінійки (pipeline) Проте через оптимізацію Spark ділить DAG на 5 Jobs



## Частина 2

Spark перераховує pipeline двічі: один раз для першого collect(), другий — для другого. Тобто Spark повторно виконує всі обчислення з нуля, бо дані не зберігались



## Частина 3

cache() каже Spark: "збережи результат цієї трансформації в пам'яті" Перший .collect()  $\rightarrow$  виконує всі трансформації та кешує результат Другий .collect() вже не перераховує DAG  $\rightarrow$  просто бере з пам'яті

